

[复习]线性代数与微积分 / Linear Algebra and Calculus refresher

翻译&校正 | 韩信子@ShowMeAI

编辑 | 南乔@ShowMeAI

原文作者 | <https://stanford.edu/~shervine>

本节原文超链

[1]通用符号 / General Notations

1.1 定义/ Definitions

向量 Vector

记 $x \in \mathbb{R}^n$ 为一个 n 维向量, 其中 $x_i \in \mathbb{R}$ 表示第 i 维元素:

$$x = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} \in \mathbb{R}^n$$

备注: 上述向量 x 可以视为一个 $n \times 1$ 矩阵, 常被称为“列向量”。

矩阵 Matrix

$A \in \mathbb{R}^{m \times n}$ 为一个 m 行 n 列的矩阵, 其中 $A_{i,j} \in \mathbb{R}$ 表示第 i 行第 j 列的元素:

$$A = \begin{pmatrix} A_{1,1} & \cdots & A_{1,n} \\ \vdots & & \vdots \\ A_{m,1} & \cdots & A_{m,n} \end{pmatrix} \in \mathbb{R}^{m \times n}$$

1.2 常用矩阵/ Main Matrices

单位矩阵 Identity matrix

单位矩阵 $I \in \mathbb{R}^{n \times n}$ 是对角线元素为 1、其余元素为 0 的方阵。

$$I = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & \ddots & & \vdots \\ \vdots & & \ddots & 0 \\ 0 & \cdots & 0 & 1 \end{pmatrix}$$

备注: 对任意 n 阶方阵 $A \in \mathbb{R}^{n \times n}$, $A \times I = I \times A = A$ 。

对角矩阵 Diagonal matrix

对角矩阵 $D \in \mathbb{R}^{n \times n}$ 是对角线元素非 0、其余元素均为 0 的方阵。

$$D = \begin{pmatrix} d_1 & 0 & \cdots & 0 \\ 0 & \ddots & & \vdots \\ \vdots & & \ddots & 0 \\ 0 & \cdots & 0 & d_n \end{pmatrix}$$

备注: D 也可以被记作 $\text{diag}(d_1, \dots, d_n)$ 。

[2]矩阵运算 / Matrix Operations

2.1 乘法/ Multiplication

向量-向量 Vector-vector

存在两种类型的向量-向量乘法:

内积: $x, y \in \mathbb{R}^n$:

$$x^T y = \sum_{i=1}^n x_i y_i \in \mathbb{R}$$

外积: $x \in \mathbb{R}^m, y \in \mathbb{R}^n$:

$$xy^T = \begin{pmatrix} x_1 y_1 & \cdots & x_1 y_n \\ \vdots & & \vdots \\ x_m y_1 & \cdots & x_m y_n \end{pmatrix} \in \mathbb{R}^{m \times n}$$

矩阵-向量 Matrix-vector

矩阵 $A \in \mathbb{R}^{m \times n}$ 和 向量 $x \in \mathbb{R}^n$ 的乘积是 m 阶向量 \mathbb{R}^m , 满足:

$$Ax = \begin{pmatrix} a_{r,1}^T x \\ \vdots \\ a_{r,m}^T x \end{pmatrix} = \sum_{i=1}^n a_{c,i} x_i \in \mathbb{R}^m$$

其中, $a_{r,i}^T$ 是矩阵 A 的行向量, $a_{c,j}$ 是矩阵 A 的列向量。 x_i 是矩阵 x 的元素。

矩阵-矩阵 Matrix-matrix

矩阵 $A \in \mathbb{R}^{m \times n}$ 和矩阵 $B \in \mathbb{R}^{n \times p}$ 的乘积是 $m \times p$ 矩阵 $\mathbb{R}^{n \times p}$ ，满足：

$$AB = \begin{pmatrix} a_{r,1}^T b_{c,1} & \cdots & a_{r,1}^T b_{c,p} \\ \vdots & & \vdots \\ a_{r,m}^T b_{c,1} & \cdots & a_{r,m}^T b_{c,p} \end{pmatrix} = \sum_{i=1}^n a_{c,i} b_{r,i}^T \in \mathbb{R}^{n \times p}$$

备注： $a_{r,i}^T$, $b_{r,i}^T$ 分别是矩阵 A 和 B 的行向量， $a_{c,j}$, $b_{c,j}$ 分别是矩阵 A 和 B 的列向量。

[3]其他矩阵 / Other Operations

转置 Transpose

矩阵 $A \in \mathbb{R}^{m \times n}$ 的转置记作 A^T 。 A^T 是对 A 的元素进行翻转：

$$\forall i, j, A_{i,j}^T = A_{j,i}$$

备注： 对矩阵 A, B , $(AB)^T = B^T A^T$ 。

逆 Inverse

可逆方阵 A 的逆矩阵记作 A^{-1} 。 A^{-1} 是唯一满足以下条件的矩阵：

$$AA^{-1} = A^{-1}A = I$$

备注： 并非所有方阵都可逆。同样，对矩阵 A, B , $(AB)^{-1} = B^{-1}A^{-1}$ 。

迹 Trace

方阵 A 的迹记作 $\text{tr}(A)$ 。 $\text{tr}(A)$ 是对角元素的和。

$$\text{tr}(A) = \sum_{i=1}^n A_{i,i}$$

备注： 对矩阵 A, B , $\text{tr}(A^T) = \text{tr}(A)$, $\text{tr}(AB) = \text{tr}(BA)$ 。

行列式 Determinant

n 阶方阵 $A \in \mathbb{R}^{n \times n}$ 的行列式，记作 $|A|$ 或者 $\det(A)$ 。可以用如下形式递归计算得到， $A_{i,j}$ 表示第 i 行第 j 列元素， $|A_{\setminus i, \setminus j}|$ 表示去掉第 i 行第 j 列后的矩阵行列式：

$$\det(A) = |A| = \sum_{j=1}^n (-1)^{i+j} A_{i,j} |A_{\setminus i, \setminus j}|$$

备注： 当且仅当 $|A| \neq 0$ 时， A 是可逆的。同样， $|AB| = |A||B|$, $|A^T| = |A|$ 。

[4]矩阵的性质 / Matrix Properties

对称分解 Symmetric decomposition

一个给定矩阵 A 可以用其对称和反对称部分进行表示：

$$A = \underbrace{\frac{A + A^T}{2}}_{\text{Symmetric}} + \underbrace{\frac{A - A^T}{2}}_{\text{Antisymmetric}}$$

范数 Norm

一个范数是一个函数 $N: V \rightarrow [0, +\infty]$ ，其中 V 是一个向量空间。对于所有 $x, y \in V$ ：

$$N(x + y) \leq N(x) + N(y)$$

对一个标量 a , $N(ax) = |a|N(x)$ 。

$N(x) = 0$ 时， $x = 0$ 。

对 $x \in V$ ，下表总结了最常用的范数：

范数	符号	定义	用例
曼哈顿, L^1	$\ x\ _1$	$\sum_{i=1}^n x_i $	LASSO
欧几里德, L^2	$\ x\ _2$	$\sqrt{\sum_{i=1}^n x_i^2}$	Ridge
p -范数, L^p	$\ x\ _p$	$\left(\sum_{i=1}^n x_i^p\right)^{\frac{1}{p}}$	赫尔德不等式
无穷, L^∞	$\ x\ _\infty$	$\max_i x_i $	一致收敛

线性相关 Linearly dependence

如果向量集中的一个向量可以定义为其他向量的线性组合，则称向量集为线性相关。

备注：若无向量可以按照此法表示，则这些向量被称为线性无关。

矩阵的秩 Matrix rank

给定矩阵 A 的秩记作 $\text{rank}(A)$ ，是由列向量生成的向量空间的维度。这等价于 A 的线性无关列向量的最大数目。

半正定矩阵 Positive semi-definite matrix

矩阵 $A \in \mathbb{R}^{n \times n}$ 是半正定矩阵 (PSD)，记作 $A \succeq 0$ 。

$$A = A^T \quad \text{和} \quad \forall x \in \mathbb{R}^n, \quad x^T A x \geq 0$$

备注：类似地，矩阵 A 被称作正定，记作 $A \succ 0$ ，当它是一个 PSD 矩阵且满足所有非零向量 x ， $x^T A x > 0$ 。

特征值，特征向量 Eigenvalue, eigenvector

给定矩阵 $A \in \mathbb{R}^{n \times n}$ ， λ 被称作 A 的一个特征值。当存在一个向量 $z \in \mathbb{R}^n \setminus \{0\}$ ，称作特征向量，满足：

$$Az = \lambda z$$

谱定理 Spectral theorem

令 $A \in \mathbb{R}^{n \times n}$ 。若 A 是对称的，则 A 可以被一个实正交矩阵 $U \in \mathbb{R}^{n \times n}$ 对角化。

记作 $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$ ：

$$\exists \Lambda \text{ diagonal}, \quad A = U \Lambda U^T$$

奇异值分解 Singular-value decomposition

给定一个 $m \times n$ 阶的矩阵 A ，奇异值分解 (SVD) 是一个因子分解机巧，能保证存在酉矩阵 $U \in \mathbb{R}^{m \times m}$ ， $\Sigma \in \mathbb{R}^{m \times n}$ 和酉矩阵 $V \in \mathbb{R}^{n \times n}$ ，满足：

$$A = U \Sigma V^T$$

[5]矩阵的微积分 / Matrix Calculus

梯度 Gradient

函数 $f: \mathbb{R}^{m \times n} \rightarrow \mathbb{R}$ ，矩阵 $A \in \mathbb{R}^{m \times n}$ 。

函数 f 关于 A 的梯度是一个 $m \times n$ 矩阵，记作 $\nabla_A f(A)$ ，如下表示：

$$(\nabla_A f(A))_{i,j} = \frac{\partial f(A)}{\partial A_{i,j}}$$

备注：当且仅当 f 是一个返回标量值的函数时， f 的梯度是有定义的。

Hessian

函数 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ ，向量 $x \in \mathbb{R}^n$ 。

那么，函数 f 关于向量 x 的海森矩阵 (Hessian Matrix) 是一个 $n \times n$ 的对称阵，记作 $\nabla_x^2 f(x)$ ，并满足：

$$(\nabla_x^2 f(x))_{i,j} = \frac{\partial^2 f(x)}{\partial x_i \partial x_j}$$

备注：当且仅当 f 是一个返回标量值的函数时， f 的海森矩阵是有定义的。

梯度运算 Gradient operations

对矩阵 A, B, C ，下列梯度性质值得记住：

$$\nabla_A \text{tr}(AB) = B^T$$

$$\nabla_{A^T} f(A) = \left(\nabla_A f(A) \right)^T$$

$$\nabla_A \text{tr}(ABA^T C) = CAB + C^T A B^T$$

$$\nabla_A |A| = |A| (A^{-1})^T$$

Awesome AI Courses Notes Cheat Sheets

Machine Learning CS229	Deep Learning CS230	Natural Language Processing CS224n	Computer Vision CS231n	Deep Reinforcement Learning CS285	Neural Networks for NLP CS11-747	DL for Self-Driving Cars 6.S094	...
Stanford	Stanford	Stanford	Stanford	UC Berkeley	CMU	MIT	...

是 **ShowMeAI** 资料库的分支系列，覆盖最具知名度的 TOP20+门 AI 课程，旨在为读者和学习者提供一整套高品质中文速查表，可以点击【[这里](#)】查看。

斯坦福大学（Stanford University）的 **Machine Learning（CS229）** 和 **Deep Learning（CS230）** 课程，是本系列的第一批产出。


本批两门课程的速查表由斯坦福大学计算机专业学生 **Shervine Amidi** 总结整理。原速查表为英文，可点击【[这里](#)】查看，**ShowMeAI** 对内容进行了翻译、校对与编辑排版，整理为当前的中文版本。

有任何建议和反馈，也欢迎通过下方渠道和我们联络 (*^__^*)

CS229 | Machine Learning @ Stanford University


监督学习

Supervised Learning


[中文速查表链接](#)


无监督学习

Unsupervised Learning


[中文速查表链接](#)


深度学习

Deep Learning


[中文速查表链接](#)

机器学习技巧和经验

Tips and Tricks


[中文速查表链接](#)

CS230 | Deep Learning @ Stanford University

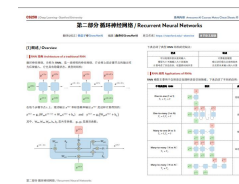
卷积神经网络

CNN


[中文速查表链接](#)

循环神经网络

RNN


[中文速查表链接](#)

深度学习技巧与建议

Tips and Tricks


[中文速查表链接](#)

概率统计

Probabilities / Statistics


[中文速查表链接](#)

线性代数与微积分

Linear Algebra and Calculus


[中文速查表链接](#)

GitHub
ShowMeAI

<https://github.com/ShowMeAI-Hub/>



ShowMeAI 研究中心

扫码回复“**速查表**”
下载**最新**全套资料